

Computación paralela y distribuida

Tarea 3: Polars

Jean Rabbat

Descripción del dataset:

El dataset "Credit Card Fraud Detection" fue recopilado y publicado por la Universidad Libre de Bruselas (ULB) en Kaggle. Contiene transacciones de tarjetas de crédito realizadas por titulares europeos en septiembre de 2013. El dataset es ampliamente utilizado en la investigación de machine learning para detección de fraude debido a su tamaño real, complejidad y características auténticas.

Resultados de machine learning:


Los 3 datasets alcanzaron un nivel de precisión bastante alto, incluso 2 llegaron al 100%, sin embargo, esto se debe a que el dataset tiene características PCA ya bien separadas. El de mejor rendimiento y velocidad lo proporcionan XGBoost que obtuvo 99.99% de precisión y 1.64 segundos de entrenamiento.

Tablas comparativas Polars vs Pandas


Operación	Polars	Pandas	Speedup	
lectura	0.1408	1.2206	8.67	x
filtrado	0.0163	0.0446	2.73	x
feature_eng	0.0015	0.0043	2.95	x
agregacion	0.0029	0.0052	1.79	x
join	0.0191	0.1302	6.82	x
Total	0.1806	1.4050	7.78	x

Los resultados son bastante contundentes... polars es mucho más rápido que pandas, en este caso 7.78 veces más rápido.

Gráficas de tiempos de ejecución



Gráficas de speedup



Discusión técnica de resultados:

¿Qué ventajas observó al utilizar Polars?

Polars es mucho más rápido que pandas siendo 7.8 veces mas rápido, la lectura de datos es 8.6 más rápida por apache arrow, donde se aprovechan los cores del sistema y mejora el manejo de la memoria.

¿Qué operaciones obtuvieron el mayor speedup?

La lectura es el que tuvo mayor speedup, seguida del join, esto gracias a sus algoritmos optimizados.

¿En cuáles operaciones la diferencia fue pequeña?

La agregación tuvo la menor diferencia con solo 1.79% de speedup ya que es una operación mas sencilla y ambas librerías están optimizadas para este tipo de operación.

¿Qué beneficios aporta Lazy Execution?

Este permite que polars optimizar el plan de ejecución antes de ejecutar las operaciones, reduce el consumo de memoria al procesar datos en streaming y eliminar operaciones que no son necesarias.

¿Qué limitaciones encontró en Polars?

Menos documentación.

¿Qué ventajas mantiene Pandas?

Comunidad mas grande con bastante documentación y recursos, además de que es mas compatible con el ecosistema de machine learning.

¿La aceleración observada justifica migrar un proyecto existente?

Si vale la pena, acá se demuestra donde el pipeline se puede ejecutar 7.7 más rápido con polars.

¿Cómo afecta el tamaño del dataset al beneficio obtenido?

El speedup aumenta significativamente con el tamaño del dataset. Con el 25% de los datos se obtiene 1.87x, con el 50% se alcanza 4.66x, con el 75% se llega a 5.14x, y con el 100% se logra 8.65x. Esto demuestra que Polars aprovecha mejor el paralelismo conforme crece el volumen de datos.

¿Qué modelo produjo el mejor desempeño predictivo?

XGBoost es el modelo más equilibrado, alcanzando 99.99% de precisión con solo 1.64 segundos de entrenamiento. Aunque Logistic Regression y Random Forest alcanzaron 100% de accuracy, XGBoost es más robusto y menos propenso al overfitting

¿Qué recomendaciones daría para proyectos futuros?

Usar polars en pipelines con grandes volúmenes de datos.